Projet GSON

« Data Sciences et langage »

Janvier 2026

Eunice SITTI-MAWUBEJRO (numéro étudiant : 22207096)

Guillaume GOUGOU (numéro étudiant : 21910902)

Étudiants en Master 2 – Mathématiques appliquées, statistiques à l'Université d'Orléans

Enseignantes référentes – Mme Anne-Lyse MINARD & Mme Katja PLOOG

Année scolaire 2025 - 2026

Table des matières

1. Introduction..... 2
1.1 Le programme GSON et le module “Data Sciences et langage”..... 2
1.2 Présentation du corpus Les Vocaux..... 2
a) Présentation générale..... 2
b) Origine des données et campagnes de recueil..... 2
c) Présentation des vocaux étudiés..... 3
2. Comparaison entre une approche humaine et une approche automatique..... 4
2.1 Le vocal “329_13”..... 4
2.2 Le vocal “344_04”..... 5
2.3 Le vocal “358_27”..... 5
3. Analyse du travail automatique de Whisper..... 6
4. Conclusion..... 7

1. Introduction

1.1 Le programme GSON et le module “Data Sciences et langage”

Dans le but d’apporter un complément de formation sur les sciences des données, l’Université d'Orléans a mis en place le programme GSON, Graduate School Orléans Numérique. Il permet aux étudiants de niveau master minimum, de prétendre à un Diplôme Universitaire. GSON vise notamment à rapprocher les approches de la donnée des domaines d’application, et à favoriser le travail en équipe pluridisciplinaire.

Dans ce cadre, le module “Data Sciences et langage” fait partie de l’offre de modules GSON et fournit un terrain applicatif privilégié pour articuler méthodes de data sciences et analyse de données langagières. Ce module a pour objectif l’initialisation aux traitements de données langagières, l’identification des problématiques et la compréhension des outils de traitement automatique.

1.2 Présentation du corpus *Les Vocaux*

a) Présentation générale

Le corpus *Les Vocaux* rassemble des sms vocaux en français. Ces sms ont été enregistrés de manière spontanée par des francophones (de France, Belgique et Canada), en dehors d’un dispositif d’enquête linguistique classique. Les vocaux ont ensuite été recueillis et anonymisés pour constituer un corpus qui, à terme, comportera les fichiers audio, une transcription orthographique, un alignement phonétique au signal etc..

Ce corpus s’inscrit dans le cadre du projet ORALIDIA (*Oralité et diachronie* : une voie d’accès au changement linguistique). Ce projet a pour objectif la constitution d’un corpus inédit de français parlé spontané et la description de la langue “naturelle”.

La version utilisée ici est la version 0.0.2, qui totalise 1196 fichiers audio pour une durée de 19h32min49sec.

b) Origine des données et campagnes de recueil

Les données proviennent de deux campagnes :

- Campagne 2021 : recueil auprès de 7 locutrices, avec 59 vocaux et 7 extraits d’entretien (utilisés comme échantillons comparatifs), pour une durée totale d’environ 1h00. Les participantes sont associées à Strasbourg et Paris.

- Campagne 2022 : appel à participation (réseaux sociaux et listes), avec consentement via questionnaire, puis dépôt libre de vocaux. Le corpus indique 45 locuteurs, pour 1160 vocaux et une durée totale d'environ 19h06.

c) Présentation des vocaux étudiés

Nous avons travaillé sur un ensemble de 3 vocaux, précisément les vocaux “329_13”, ”344_04” et “358_27” du corpus.

Le premier (“329_13”) a une durée de 2 minutes et est un message informatif où la locutrice détaille l'état d'avancement et les difficultés d'un dossier de régularisation. On observe une succession d'éléments ainsi que des marqueurs d'hésitation fréquents. Le vocal se termine par une formule de remerciement et une marque d'affection, avec un nom anonymisé par un bip sonore, retranscrit via la balise “#anon”.

Le deuxième (”344_04”) a une durée de 47 secondes et correspond à une réponse adressée, dans un registre familier. La locutrice réagit à des informations manifestement partagées auparavant et alterne entre commentaires et questions implicites.

Enfin, le troisième et dernier vocal (“358_27”) a une durée de 2 minutes et 11 secondes et est un compte rendu de rendez-vous médical adressé à une proche, avec une structure narrative relativement stable comparée aux autres vocaux. Le discours est marqué par de nombreuses reformulations et auto-corrections, ainsi que par des commentaires humoristiques, ce qui contribue à un style très proche de la conversation.

2. Comparaison entre une approche humaine et une approche automatique

L'analyse des trois vocaux a été menée à l'aide du logiciel Praat, utilisé comme environnement de référence pour la segmentation temporelle.

Dans un premier temps, nous avons procédé à une écoute intégrale de chaque message afin d'identifier la thématique générale et les indices prosodiques susceptibles de signaler des ruptures (pauses, allongements, variations d'intonation, tics de langage...).

Dans un second temps, nous avons proposé une segmentation et une transcription en nous appuyant sur la transcription de référence du corpus. Le travail étant réalisé en binôme, nous avons d'abord produit deux segmentations indépendantes, puis nous avons comparé nos propositions afin d'aboutir à un rendu harmonisé. Cette étape de mise en cohérence a été utile pour expliciter et mettre au point une procédure commune, notamment sur ce qui constitue, de notre point de vue, une "bonne" frontière de segment et sur le compromis à adopter entre structure syntaxique claire et indices prosodiques.

Notre principe directeur a été, autant que possible, de définir des segments correspondant à des unités linguistiques complètes et interprétables, proches de la phrase au sens sujet–verbe–complément. Toutefois, dans l'oral spontané, les structures sont souvent inachevées, reformulées ou interrompues : nous avons donc également pris en compte la prosodie pour nos segmentations.

En amont, l'outil Whisper a été utilisé pour obtenir une segmentation automatique. L'objectif de cette section est donc de réaliser une comparaison qualitative entre notre segmentation manuelle et la segmentation produite automatiquement par Whisper.

2.1 Le vocal "329_13"

Au total, nous avons réalisé un total de 25 segmentations, là où l'outil Whisper en a lui fait 29.

La première différence que nous avons constatée est que l'outil Whisper ne retranscrit pas les hésitations ou tic du langage tel que le "euh..", il les gomme directement. De notre côté, nous les avons considérés soit comme :

- une pause totale avant de reprendre une phrase (exemple : intervals [3], xmin = 12.224319204297158, xmax = 14.660678121487202, text = "Euh...").
- faisant partie d'une phrase car il ne marquait pas un temps d'arrêt assez long et qu'on ne pouvait pas donner de sens au groupe de mots suivant (exemple : intervals [5], xmin = 16.30673469387755, xmax = 22.673492063492066, text = "Euh...La préfecture de Dijon n'étant pas une préfecture qui, euh..., facilite euh... ces demandes-là. ").

La deuxième différence que nous avons notée est qu'il arrive à Whisper de rajouter des mots à la transcription, que la locutrice n'a jamais prononcés, comme une sorte d'hallucination auditive. Un bon exemple serait le suivant : intervals [13], xmin = 58.759999999999998, xmax = 58.79999999999999, text = "l'entreprise est en recours avec l'avocate,". Il a tout simplement rajouté l'entièreté de cette phrase, qui n'a pas été dite par la locutrice.

Une troisième différence est que l'outil Whisper omet certains lemmes. En effet, de xmin = 75.57015460762632 à xmax = 78.91390109529036, que nous avons transcrit par : "voilà je euh qu' est -ce que je peux te dire d'autre euh", Whisper le transcrit par : "Voilà, qu'est-ce que je peux te dire d'autre ?". En plus du "euh.." dont nous avons déjà parlé précédemment, il a également omis le "je", qui a pourtant bien été prononcé.

Enfin, la quatrième et dernière différence que nous avons relevée est que Whisper n'a pas tenu compte de l'anonymisation dans sa transcription. De xmin = 118.55715984546637 à xmax = 119.88, ce que nous avons transcrit par : "merci pour tout #anon je t'aime", Whisper l'a transcrit, à cause du bip sonore, par "Merci pour tout, je t'aime."

2.2 Le vocal "344_04"

Ici, nous avons découpé le vocal en un total de 15 segments, et Whisper 24. Cette différence significative s'explique en particulier par le fait que les hésitations et les répétitions sont ignorées lors de la transcription et de la segmentation automatique, alors que nous les avons évidemment gardées et avons dû faire avec.

Par exemple de xmin = 11.40381941315744 à xmax = 15.667646833761053, notre transcription est : "qui … qui est allé aussi il m' a raconté qu'il y avait deux week-ends en entier", alors que celle de Whisper est : "qui est allé aussi, il m'a raconté".

Ce vocal étant par contre particulièrement court, nous n'avons pas relevé plus de différences ou erreurs.

2.3 Le vocal "358_27"

Ce vocal a été segmenté en 25 intervalles par Whisper tandis que nous en avons trouvé 31. Sur celui-ci, nous avons constaté que la locutrice possédait un tic du langage qu'elle répétait systématiquement à chaque début ou fin de phrase, ce qui a rendu la segmentation assez rapide.

Mise à part les "euh.." d'hésitation, Whisper a assez fidèlement retranscrit le message. Nous avons cependant relevé, de nouveau, un cas d'hallucination. En effet, de xmin = 54.600000000000001 à xmax = 54.659999999999997, il a ajouté la phrase : "comme elle m'a dit, je vais faire une seconde gastrite en février.", que la locutrice n'a pas prononcée.

3. Analyse du travail automatique de Whisper

Dans l'ensemble, Whisper fait un travail assez remarquable. Il a bien retranscrit la majorité des phrases, respecté la négation même lorsque la locutrice avait omis le "ne". En effet, dans le troisième vocal, de xmin = 24.680000000000000 à xmax = 31.859999999999999, il a transcrit : "Donc elle m'a dit qu'elle ne voyait pas l'intérêt de faire de fibro maintenant, elle m'a dit bon vous avez 30 ans, c'est hyper invasif.".

Nous avons constaté que Whisper cherchait à faire une segmentation qui respecte les tournures de phrase. En ce qui concerne les temps, ses intervalles tombent le plus souvent sur des temps qui terminent soit par 000, soit 999, serait-ce intentionnel ?

Mais Whisper fait également des erreurs, il n'y a aucune référence au fait que dans les vocaux, les locutrices se reprennent après avoir déjà commencé un mot. Il transcrit alors le mot qu'il a "compris". Par exemple dans le vocal "329_13", de xmin = 109.319999999999993 à xmax = 114.000000000000000, il a transcrit : "Sinon, au niveau des pièces scolaires, il nous manque quelques bustins et certificats de scolarité," alors que la locutrice a dit "bulletins" mais en hésitant au milieu du mot.

Également, comme mentionné plus tôt, Whisper n'a pas respecté le bip sonore d'anonymisation du premier vocal étudié.

Une tentative de catégorisation des erreurs pourrait être la suivante :

- **L'omission des onomatopées :** les tics du langage tels que le "euh", le "hum" sont souvent ignorés et n'apparaissent que très rarement dans les transcriptions.
- **Les hallucinations :** la transcription automatique ajoute des mots ou des phrases entières qui n'ont cependant jamais été prononcés. Dans la première note vocale par exemple, il a, à un moment, rajouté le mot "demain", serait-ce parce que la tournure de phrase s'y prêtait ?
- **L'omission de mots :** en effet, il lui arrive également d'oublier certains mots dans ses transcriptions.

4. Conclusion

Ce projet, nous a permis de travailler sur un objet de données langagières concret et d'articuler une démarche analytique avec une première évaluation d'un outil de traitement automatique. L'exploitation du corpus Les Vocaux nous a confronté aux caractéristiques de l'oral spontané : hésitations, reformulations, pauses... Le choix de trois vocaux contrastés a été un point fort : il met en évidence des styles différents et des difficultés variées pour la segmentation et la transcription.

La comparaison entre notre segmentation manuelle sous Praat et la segmentation automatique par Whisper montre que l'automatisation produit des résultats globalement stables et bien exploitables, mais avec un comportement systématique qui n'est pas neutre.

D'un côté, Whisper fournit une transcription grammaticalement cohérente, et tend à segmenter selon des unités proches de la phrase. De l'autre, il "normalise" fortement l'oral : il gomme les hésitations et tics de langage, réduit certaines répétitions, et ne rend pas compte de phénomènes comme les amorces de mots (début interrompu). Ce choix implicite peut être problématique si ces marqueurs font l'objet d'études.

Nous avons également observé des erreurs plus critiques, en particulier des « hallucinations » et des omissions de mots, ainsi que l'absence de prise en compte de l'anonymisation par bip, qui peuvent conduire à une perte d'information ou à une interprétation incorrecte du passage concerné.

Au final, Whisper apparaît comme un outil performant pour obtenir rapidement une première transcription et une segmentation, mais son utilisation pertinente suppose une relecture humaine. Le traitement automatique accélère et standardise, tandis que l'humain garantit l'interprétation linguistique fine, la prise en compte du contexte et le respect des spécificités du corpus (ici l'anonymisation).

Cette expérience nous a ainsi donné une vision plus concrète des conditions dans lesquelles les outils de traitement automatique peuvent être mobilisés de manière rigoureuse dans l'analyse de données langagières.